

Nghiên cứu mô hình Ensemble tối ưu hóa cho môi trường có tài nguyên hạn chế

Research on Optimized Ensemble Model for Resource-Constrain Environments

✉ Võ Anh Nhật

Viện công nghệ thông tin và điện, điện tử

Trường Đại học Giao thông vận tải
Thành phố Hồ Chí Minh
voanhnhathat1612@gmail.com

Dur Quốc Việt

Viện công nghệ thông tin và điện, điện tử

Trường Đại học Giao thông vận tải
Thành phố Hồ Chí Minh
Duviet720@gmail.com

Võ Huỳnh Anh Tuấn

Viện công nghệ thông tin và điện, điện tử

Trường Đại học Giao thông vận tải
Thành phố Hồ Chí Minh
vohuynhanhtuan0512@gmail.com

Trương Hoài Tú

Viện công nghệ thông tin và điện, điện tử
Trường Đại học Giao thông vận tải Thành phố Hồ Chí Minh
hoaitu163@gmail.com

Trần Anh

Trường Phổ thông Năng khiếu,
Đại học Quốc gia Thành phố Hồ Chí Minh
kingtrananh@gmail.com

Tóm tắt - Dự báo lượng mưa ngắn hạn là bài toán quan trọng nhưng nhiều thách thức do dữ liệu mưa có tính phi tuyến cao, phân phối mất cân bằng với nhiều giá trị bằng 0 và xuất hiện các giá trị cực đoạn, đặc biệt tại khu vực Đồng bằng sông Cửu Long. Trong khi các mô hình học sâu thường yêu cầu tài nguyên tính toán lớn và dễ quá khớp, các mô hình học máy đơn lẻ lại có độ ổn định chưa cao. Trên cơ sở đó, nghiên cứu đề xuất hệ thống VN Weather Hub, được thiết kế theo hướng tối ưu cho môi trường có tài nguyên hạn chế. Hệ thống gồm ba thành phần chính: module thu thập dữ liệu đa nguồn từ 52 trạm quan trắc, tích hợp Open-Meteo, OpenWeather, OpenWeatherMap và Vrain theo cơ chế ưu tiên tuần tự; pipeline xử lý dữ liệu gồm gộp, làm sạch, kỹ thuật đặc trưng và chuyển đổi theo lược đồ 43 trường; và mô hình Stacking Ensemble hai tầng với 8 mô hình cơ sở và 2 meta-learners [mô hình học bậc 2]. Kết quả thực nghiệm cho thấy Stacking Ensemble cải thiện khả năng tổng quát hóa, giảm overfitting (quá khớp) và đạt hiệu quả tốt ở các chỉ số Rain F1, R^2 , RMSE, đồng thời vẫn phù hợp triển khai trên hạ tầng cục bộ không yêu cầu bộ xử lý đồ họa.

Từ khóa - Học tập kết hợp, Mô hình Stacking Ensemble, Dự báo lượng mưa, Hệ thống dự báo thời tiết.

Abstract - Short-term rainfall forecasting is an important yet challenging task due to the highly nonlinear nature of rainfall data, its imbalanced distribution with many zero values, and the presence of extreme values, particularly in the Mekong Delta region. While deep learning models often require substantial computational resources and are prone to overfitting, single machine learning models tend to lack stability. Based on this context, this study proposes VN Weather Hub, a system designed to be optimized for resource-constrained environments. The system consists of three main components: a multi-source data collection module from 52 observation stations, integrating Open-Meteo, OpenWeather,

OpenWeatherMap, and Vrain through a priority fallback mechanism; a complete data processing pipeline including merging, cleaning, feature engineering, and transformation based on a 43-field data schema; and a two-layer Stacking Ensemble model with 8 base models and 2 meta-learners. Experimental results show that the Stacking Ensemble improves generalization, reduces overfitting, and achieves strong performance in key metrics such as Rain F1, R^2 , and RMSE, while remaining suitable for deployment on local infrastructure without requiring a Graphics Processing Unit.

Keywords - Ensemble Learning, Stacking Ensemble Model, Rainfall Forecasting, Weather Forecasting System.

I. GIỚI THIỆU

Dự báo lượng mưa ngắn hạn là bài toán khó do tính phi tuyến cao. Đặc biệt tại Đồng bằng sông Cửu Long (ĐBSCL), khu vực chịu ảnh hưởng nặng của biến đổi khí hậu và lũ lụt theo mùa, nhu cầu về một hệ thống dự báo chính xác, ổn định và có khả năng triển khai trên hạ tầng tài nguyên hạn chế (không yêu cầu bộ xử lý đồ họa) ngày càng cấp thiết. Trong những năm gần đây, các mô hình học sâu được đề xuất cho bài toán khí tượng, song đòi hỏi khối lượng dữ liệu và chi phí tính toán lớn, dễ gặp vấn đề quá khớp và mất ổn định [1]. Vì vậy, học kết hợp (ensemble learning) nổi lên như một hướng tiếp cận thay thế hiệu quả nhờ khả năng giảm phương sai và tăng độ tổng quát hóa [1],[2]. Trong đó, Stacking Ensemble cho thấy hiệu quả vượt trội do có thể học trọng số kết hợp phi tuyến giữa các mô hình cơ sở thông qua một mô hình học siêu cấp [3],[4]. Tuy nhiên, khi áp dụng Stacking Ensemble cho dự báo mưa theo chuỗi thời gian trên tài nguyên hạn chế, vẫn tồn tại bốn thách thức chính:

- (1) Rò rỉ dữ liệu khi dùng phần tập con ngẫu nhiên cho chuỗi thời gian [5];
- (2) Bài toán kép làm phát số 0 - vừa phân loại "có

mưa / không mưa" vừa hồi quy lượng mưa - nhưng gộp chung một quy trình xử lý làm mô hình lệch về lớp đa số [6];

(3) Thiếu cơ chế định tuyến theo ngữ cảnh (mùa mưa / mùa khô, cường độ mưa);

(4) Đánh đổi giữa độ chính xác và chi phí tính toán.

Từ đó, nghiên cứu này đề xuất và triển khai nền tảng web tích hợp mô hình Stacking Ensemble hai tầng tối ưu cho môi trường tài nguyên hạn chế, với bốn đóng góp chính:

(1) Kiến trúc Stacking Ensemble;

(2) Chiến lược OOF (Out-Of-Fold) [Ngoài tập gập];

(3) Định tuyến nhận biết ngữ cảnh;

(4) Triển khai end-to-end [Đầu cuối] trên tài nguyên hạn chế: đóng gói Docker 3 tầng (MongoDB [-Machine-learning [Học máy] – Django), mô hình chỉ nặng 23.79 MB, chạy hoàn toàn trên máy chủ cục bộ không cần bộ xử lý đồ họa.

II. CÁC CÔNG TRÌNH LIÊN QUAN

A. Các nghiên cứu ứng dụng phương pháp Ensemble

Ensemble đã được ứng dụng sâu rộng trong nhiều lĩnh vực khác nhau:

Điển hình là nghiên cứu của Sampson và các cộng sự, trong đó họ đã tối ưu hóa bài toán dự đoán bệnh ung thư vú thông qua các phân tích so sánh khi áp dụng mô hình máy học Stacking Ensemble, tận dụng các kỹ thuật tính toán tiên tiến này có khả năng cải thiện đáng kể kết quả của bệnh nhân và giảm tỷ lệ tử vong, đồng thời đề xuất để dự đoán ung thư vú có thể được tích hợp vào quy trình làm việc lâm sàng hiện có như một công cụ hỗ trợ quyết định[3] ;

Trong một bài toán khác về an ninh mạng, Ali và các cộng sự đã sử dụng mô hình Stacking Ensemble kết hợp với kỹ thuật chọn lọc đặc trưng nâng cao để phát hiện các cuộc tấn công Từ chối Dịch vụ Phân tán (DDoS). Các phương pháp lựa chọn tính năng truyền thống gặp khó khăn với sự phức tạp của dữ liệu lưu lượng mạng, dẫn đến hiệu suất phát hiện kém. Để giải quyết vấn đề này, lựa chọn tính năng bao bọc thuật toán di truyền (GAWFS) được đề xuất, tích hợp các phương pháp tiếp cận Chi-squared và thuật toán di truyền (GA) với phương pháp tương quan để chọn các tính năng tương quan nhất[4],[7] ;

B. Giới thiệu về các thuật toán và mô hình được sử dụng

1) Giới thiệu về các thuật toán

Về quốc tế, XGBoost [Thuật toán tăng cường gradient cực độ] [8] đã trở thành tiêu chuẩn vàng cho dữ liệu tabular nhờ regularization L1/L2 tích hợp, xấp xỉ Taylor bậc hai cho tối ưu hàm mục tiêu, và khả năng xử lý missing value natively.

LightGBM [Thuật toán tăng cường gradient dựa trên cây] [9] cải tiến tốc độ 3-10 lần nhờ hai kỹ thuật chính. GOSS [Lấy mẫu một phía dựa trên gradient] giữ toàn bộ mẫu có gradient lớn và lấy ngẫu nhiên mẫu từ

phần còn lại với trọng số bù, giảm số mẫu tính gain mà vẫn xấp xỉ chính xác. EFB [Gộp nhóm đặc trưng loại trừ lẫn nhau] nhóm các đặc trưng thừa (hiếm khi cùng khác 0) thành bundle, giảm đáng kể số chiều.

CatBoost [Thuật toán tăng cường gradient với mã hóa biến phân loại] [10] giải quyết vấn đề rò rỉ nhãn trong mã hóa biến phân loại. Với mã hóa theo trung bình của biến mục tiêu truyền thống, mẫu hiện tại xuất hiện trong tử số gây rò rỉ dữ liệu.

Random Forest [Rừng ngẫu nhiên] [11] là sự kết hợp của các bộ dự báo theo cây sao cho mỗi cây phụ thuộc vào các giá trị của một vector ngẫu nhiên được lấy mẫu độc lập và có cùng phân phối đối với tất cả các cây trong rừng. Sai số tổng quát hóa cho rừng hội tụ gần như chắc chắn đến một giới hạn khi số lượng cây trong rừng trở nên lớn.

BẢNG I. VAI TRÒ CỦA TỪNG THUẬT TOÁN TRONG MÔ HÌNH ENSEMBLE ĐỀ XUẤT.

Thuật toán	Vai trò trong giải pháp
XGBoost	Base learner [Người học cơ sở] chủ lực, cung cấp dự báo có regularization mạnh
LightGBM	Base learner tốc độ cao, hỗ trợ Tweedie loss phù hợp phân phối zero-inflated [lạm phát số 0] của rain_total (tỷ lệ zero $\approx 85.3\%$)
CatBoost	Base learner xử lý các đặc trưng phân loại (Tỉnh/Thành phố, Tên trạm, Huyện, Tình trạng) mà không gây mất mát
Random Forest	Base learner đóng gói - tạo nguồn đa dạng khác biệt với 3 mô hình tăng cường còn lại

2) Giới thiệu về mô hình được sử dụng

Stacking Ensemble cho phép kết hợp nhiều mô hình học máy thông qua một meta-learner, từ đó tận dụng ưu điểm của từng mô hình thành phần nhằm nâng cao độ chính xác và khả năng tổng quát hóa. Nhiều nghiên cứu đã chỉ ra rằng Stacking thường đạt hiệu suất vượt trội so với các mô hình đơn lẻ và các phương pháp ensemble khác trong nhiều bài toán thực tế[3],[4] .

III. KIẾN TRÚC HỆ THỐNG

A. Tổng quan về kiến trúc ba tầng

VN Weather Hub được thiết kế theo kiến trúc ba tầng phân lớp (Three-Tier Architecture [Kiến trúc ba tầng]), phân tách rõ ràng trách nhiệm giữa ba thành phần độc lập: tầng dữ liệu, tầng học máy và tầng giao diện.

- Luồng huấn luyện (Ngoại tuyến): Dữ liệu CSV [Giá trị phân tách bằng dấu phẩy] thô → Thực hiện kỹ thuật tạo đặc trưng (feature engineering) và huấn luyện mô hình → Artifacts (model, pipeline, metadata [Siêu dữ liệu]) được xuất ra tệp.

- Luồng suy luận (trực tuyến): HTTP [Giao thức truyền tải siêu văn bản] yêu cầu từ người dùng → Web Layer xác thực và xử lý → Machine-learning Layer tải các tài nguyên đã huấn luyện và thực hiện dự đoán → HTTP phản hồi trả kết quả dự báo.

B. Tầng dữ liệu

MongoDB được triển khai theo mô hình Replica Set gồm 3 node chạy đồng thời trên 3 cổng, hỗ trợ Auto-discovery [Tự động phát hiện] PRIMARY [Nút chính], xử lý lỗi có kiểm soát, transaction [Giao dịch] đa tài liệu và TTL (Time-To-Live [Thời gian sống]) Index tự động để dọn dẹp dữ liệu tạm thời mà không cần tác vụ định kỳ bên ngoài.

C. Tầng học máy

- Giai đoạn 1 - Feature Engineering: Từ 43 trường thô, module xây dựng các đặc trưng dẫn xuất. Tiếp theo, các polynomial features [đặc trưng đa thức] được tạo từ các đặc trưng top SHAP [SHapley Additive exPlanations]. Cuối cùng, chọn ra 71 đặc trưng tối ưu.

- Giai đoạn 2 - Chuẩn hóa: Pipeline 4 bước gồm:

- (1) Điền giá trị thiếu bằng trung vị;
- (2) Giới hạn giá trị ngoại lai theo IQR (Khoảng tứ phân vị)
$$(Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR) \quad (1)$$
- (3) Mã hóa nhãn cho biến phân loại;
- (4) Chuẩn hóa dữ liệu theo thang đo chuẩn. Pipeline được lưu lại qua joblib [Thư viện lưu trữ đối

tượng Python] để đảm bảo suy luận sử dụng đúng cùng phép biến đổi.

- Giai đoạn 3 - Huấn luyện: Nghiên cứu tiến hành đánh giá kiến trúc Stacking Ensemble - Super Learner 2 tầng.


- Giai đoạn 4 - Xuất Artifacts.

D. Tầng giao diện

Tầng giao diện được tổ chức theo các module chức năng chính như crawl [Thu thập dữ liệu], dataset [Tập dữ liệu], train [Huấn luyện], dự báo thời tiết và xác thực người dùng. Hệ thống sử dụng LangMiddleware [Phần mềm trung gian] để nhận diện ngôn ngữ, JWT (JSON Web Token) HS256 cho xác thực, Docker để tách crawler service khỏi máy chủ web, và Apache Airflow để lập lịch crawl tự động. Đồng thời, hệ thống bảo mật đa lớp với OTP qua SMTP [Giao thức truyền thư điện tử đơn giản], băm mật khẩu bằng, chống giả mạo CSRF [Giả mạo yêu cầu chéo trang], và API key lưu trong biến môi trường.

IV. THU THẬP VÀ XỬ LÝ DỮ LIỆU

A. Tổng quan quy trình thu thập dữ liệu



Hình 1. Tổng quan quy trình thu thập dữ liệu.

B. Thu thập dữ liệu API từ nhiều nguồn với cơ chế Priority Fallback

Hệ thống áp dụng mô hình ưu tiên tuần tự, lấy dữ liệu từ nguồn phản hồi thành công đầu tiên theo thứ tự: Open-Meteo API → WeatherAPI.com → OpenWeatherMap → fallback thống kê khí hậu. Sau khi thu thập, dữ liệu được chuẩn hóa bằng cách chuyển đổi đơn vị, tính max/min/avg trong 24 giờ cho 7 chỉ tiêu khí tượng, tính hướng gió trung bình bằng arctan2 để tránh sai lệch tại ranh giới 0°/360°, đồng thời suy luận xác suất sấm sét từ mã thời tiết WMO kết hợp các chỉ số như lượng mưa, độ ẩm và nhiệt độ. Khi cả 3 API không phản hồi, hệ thống tạo dữ liệu xấp xỉ dựa trên vùng khí hậu Việt Nam theo vĩ độ và mùa, sau đó gán nhãn data_quality = "low". Quy trình được xử lý đa luồng bằng ThreadPoolExecutor(max_workers=5), có jitter để giảm tải truy vấn, và được tích hợp vào Apache Airflow để tự động vận hành 3 ca mỗi ngày.

C. Thu thập dữ liệu lượng mưa từ HTML của VRAIN bằng Selenium [Công cụ tự động hóa trình duyệt Selenium] kết hợp Regex [Biểu thức chính quy]

Hệ thống crawl dữ liệu Vrain bằng Selenium Chrome ở chế độ headless, tối ưu cho Docker với các tùy chọn như --no-sandbox, --disable-dev-shm-usage, tắt tải ảnh và dùng page_load_strategy="eager" để tăng tốc. Với mỗi tỉnh, Chrome driver được khởi tạo, truy cập URL, chờ các phần tử dữ liệu xuất hiện trong tối đa 30 giây và tạm dừng ngắn để Angular kết xuất đầy đủ. Dữ liệu được trích xuất bằng Regex và CSS selector, bao gồm tên tỉnh, tên trạm, lượng mưa, huyện/xã và trạng thái mưa. station_id được gán theo tên trạm; đồng thời sử dụng seen_stations kết hợp threading.Lock() để tránh trùng lặp khi crawl đa luồng. Trước khi crawl từng tỉnh, hệ thống truy cập trang chủ vrain.vn/landing để lấy mốc thời gian cập nhật thống nhất, gồm ngày và giờ dữ liệu, nhằm đảm bảo tính đồng bộ cho toàn bộ bản ghi.


D. Thu thập dữ liệu VRAIN bằng Selenium đa luồng nâng cao

Hệ thống được tối ưu bằng cách mỗi thread sử dụng một Chrome driver riêng và tái sử dụng trong suốt quá trình crawl, sau đó đóng hoàn toàn khi hoàn thành, giúp giảm thời gian khởi động và tránh lỗi tích lũy trạng thái.

Tên tỉnh được lấy trực tiếp từ URL_PROVINCE_MAP thông qua province_override, thay vì trích xuất từ HTML, nhằm đảm bảo nhân tỉnh chính xác ngay cả khi trang bị redirect hoặc hiển thị sai tiêu đề.


Hiệu năng và độ ổn định được cải thiện bằng cách nâng số luồng tối đa từ 6 lên 8, tăng số lần retry từ 2 lên 3, đồng thời áp dụng cơ chế CSS Selector Waterfall để thử tuần tự nhiều selector khi cấu trúc website thay đổi. Ngoài ra, toàn bộ chuỗi tiếng Việt được chuẩn hóa Unicode về dạng NFC trước khi so sánh, giúp loại bỏ trùng lặp giả do khác biệt mã hóa.

E. Hợp nhất dữ liệu



Hình 2. Tổng quan quy trình hợp nhất dữ liệu.

F. Quy trình làm sạch



Hình 3. Tổng quan quy trình làm sạch dữ liệu.

V. Chuỗi quy trình xử lý trong học máy

A. Chia dữ liệu

Dữ liệu đầu vào gồm 43 cột chuẩn được chia thành ba tập: train 80%, validation [Kiểm định] 10%, test [kiểm tra] 10%. Nguyên tắc: không sử dụng xáo trộn nhằm đảm bảo tập kiểm tra phản ánh dữ liệu tương lai so với tập huấn luyện, tránh rò rỉ dữ liệu. Nếu cột timestamp [Dấu thời gian] tồn tại, dữ liệu được sắp xếp theo thời gian trước khi chia. Bốn cột rain bị loại để tránh mất mát: rain_current, rain_avg, rain_max, rain_min.

B. Kỹ thuật xây dựng các đặc trưng

Đặc trưng trễ: $x_{lag}(t) = x(t - k)$ (2) với $k \in \{1, 3, 6, 12, 24, 168\}$ giờ. Giúp model [Mô hình] học xu hướng: nếu 1–3h có mưa, khả năng cao bây giờ vẫn mưa; lag [Trễ] 168 giờ (1 tuần) nắm bắt chu kỳ tuần.

Đặc trưng trượt: $froll(t, w) = agg(x(t - w + 1), \dots, x(t))$ (5) với $w \in \{3, 6, 12, 24, 168\}$ giờ (3), agg [Hàm tổng hợp] $\in \{mean [Trung bình], std [Độ lệch chuẩn], min, max\}$. Tổng khoảng $5 \times 4 \times n_columns$ rolling features [Đặc trưng trượt].

Đặc trưng thời gian: mã hóa chu kỳ bằng sin và cos bảo toàn quan hệ tuần hoàn (giờ 23 và 0 gần nhau). Phân mùa theo khí hậu Việt Nam: Bắc Bộ 4 mùa, Nam Bộ 2 mùa mưa/khô.

Đặc trưng vị trí: vĩ độ, kinh độ cho phép model mô hình học khí hậu địa phương.

Đặc trưng tương tác: Các tích chéo (nhiệt độ $\times$ độ ẩm, áp suất $\times$ gió) phản ánh cơ chế vật lý tạo mưa.

Đặc trưng khác: $\Delta_{xk}(t) = x(t) - x(t - k)$ (4) phát hiện thay đổi đột ngột (nhiệt độ giảm nhanh, áp suất xuống) báo hiệu mưa.

Đa thức: Top-k features tương quan cao nhất $\rightarrow$ bình phương + tích chéo.

C. Lựa chọn đặc trưng

BẢNG II. BẢNG QUÁ TRÌNH FEATURE SELECTION.

Bước	Transformer (Mô hình Transformer)	Chiến lược mặc định	Mô tả
1	Bộ xử lý giá trị thiếu (MissingValueHandler [Bộ xử lý giá trị thiếu])	median [Trung vị]	Lấy median từ train, áp dụng cho val/test. Hỗ trợ: mean, most frequent, constant [Hằng số], KNN, ffill/bfill
2	Outlier Handler	IQR	Tính Q1, Q3, IQR trên train. Clip ngoài $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ (1). Edge case: $IQR=0 \rightarrow$ fallback min/max
3	CategoricalEncoder [Mã hóa]	Label [Nhãn]	LabelEncoder [Mã hóa] (0, 1, 2, ...). Hỗ trợ: onehot, ordinal, target encoding [Mã hóa]

4	WeatherScaler [Bộ chuẩn hóa thời tiết]	Standard [Tiêu chuẩn]	z-score: $(X - \mu) / \sigma$ (5). Hỗ trợ: min/max, robust [Mạnh mẽ]
---	--	-----------------------	---

- Nguyên tắc fit-only-on-train: Pipeline được fit() chỉ trên tập train, rồi chuyển đổi cho tập validation và test - ngăn mất mát dữ liệu từ tập kiểm tra.

- Log1p target transform: Log1p được xử lý nội bộ bên trong model (không cần áp dụng bên ngoài). zero_ratio thực tế = 37%.

- Đóng gói: Pipeline lưu bằng joblib.dump dùng đúng median/ bounds/ encoders/scaler đã fit khi train.

D. Huấn luyện mô hình

1) Tổng quan training pipeline

Hệ thống hỗ trợ 5 loại mô hình: RandomForest, XGBoost, LightGBM, CatBoost và Stacking Ensemble (Super Learner 2 tầng với 8 mô hình cơ sở + 2 meta-learner).


2) Stacking Ensemble - Super Learner 2 tầng

Stacking Ensemble sử dụng kiến trúc 2 tầng, tách bài toán dự báo mưa thành 2 sub-task riêng biệt:

- Tầng 1A - Classification Super Learner: 4 (classifiers XGBClassifier [Bộ phân loại XGBoost], RandomForest Classifier [Bộ phân loại Rừng ngẫu nhiên], CatBoost Classifier [Bộ phân loại CatBoost], LGBM Classifier [Bộ phân loại]) trả lời "Có mưa hay không?"

- Tầng 1B - Regression Super Learner: 4 regressors [Bộ hồi quy](XGBRegressor [Bộ hồi quy XGBoost], RandomForest Regressor [Bộ hồi quy Rừng ngẫu nhiên], CatBoost Regressor [Bộ hồi quy CatBoost], LightGBM Regressor [Bộ hồi quy LightGBM]) trả lời "Nếu có mưa, bao nhiêu mm?"

- Tầng 2 - Routing: Kết hợp 2 meta-learner (LGBMClassifier + LGBMRegressor) để đưa ra quyết định cuối cùng.



Hình 4. Mô hình tập hợp xếp chồng.

BẢNG III. BẢNG QUY TRÌNH HUẤN LUYỆN STACKING ENSEMBLE.

Bước	Tên	Mô tả
1	Load Config [Nạp cấu hình]	Đọc train_config.json → mục stacking (n_splits, predict_threshold, cls_params, meta_params)
2	Load Data [Nạp dữ liệu] + Schema	Nạp CSV, chuẩn hóa 43 trường tiếng Anh
3	Chia dữ liệu	Chia 80/10/10, shuffle [Xáo trộn]=False, sort_by_time=True (bảo toàn thứ tự thời gian)
4	Build Features [Xây dựng đặc trưng] + Clean	Auto-detect data type → nếu cross_sectional: tắt lag/rolling/diff. Loại constant + static features. Optional: SHAP selection + polynomial
5	Transform Pipeline	Impute [Điền giá trị thiếu] → Outlier → Encode [Mã hóa] → Scale [Chuẩn hóa] (fit on train only)

6	Feature List [Danh sách đặc trưng]	Lưu Feature_list.json để suy luận giữ đúng columns
7	Train Stacking Ensemble	4 giai đoạn nội bộ: Kiểm tra → Phân loại OOF → Hồi quy OOF → Refit [Huấn luyện lại]
8	Đánh giá	3 nhóm metrics: Classification (F1, ROC-AUC [Diện tích dưới đường cong ROC]), Regression rainy-only (MAE [Sai số tuyệt đối trung bình], RMSE), End-to-end (R ² , Rain_Detection_Accuracy [Độ chính xác tổng thể])
9	Overfit Diagnosis [Chẩn đoán hiện tượng quá khớp]	Gap Rain_F1 > 0.10 → overfit [Quá khớp]. Ưu tiên: Rain_Detection_Accuracy > Rain_F1 > R ²
10	Save Artifacts [Lưu tạo tác]	Model.pkl (chứa 8 mô hình cơ sở + 2 meta đã refit), Transform_pipeline.pkl, Feature_list.json, Metrics.json, Train_info.json


3) Tối ưu siêu tham

Cung cấp class HyperparameterTuner hỗ trợ 3 phương pháp: GridSearch [Tìm kiếm lưới], RandomSearch [Tìm kiếm ngẫu nhiên], Optuna TPE [Tối ưu siêu tham số Optuna TPE]. Optuna sử dụng TPESampler [Bộ lấy mẫu ước lượng Parzen cây] (Tree-structured Parzen Estimator) + MedianPruner [Bộ cắt tia trung vị], xây dựng mô hình xác suất cho hàm mục tiêu $P(x | y)$

E. Dự báo (Forecasting /)

1) Tổng quan forecasting pipeline

Hệ thống cung cấp cơ chế dự báo bằng Stacking Ensemble với pipeline như sau:



Hình 5. Tổng quan quy trình dự báo.

2) Nạp Artifacts [Nạp tạo tác]

BẢNG IV. BẢNG CÁC MODEL ĐƯỢC LOAD.

File	Mô hình Stacking Ensemble
Model.pkl	Stacking Ensemble (cls + reg stack + meta-models)
Transform_pipeline.pkl	WeatherTransform Pipeline đã fit
Feature_list.json	all_feature_columns (71 features), target_column, created_features
Train_info.json	Thêm stacking_config, artifacts, schema_model_bank

3) Input

Input là một DataFrame [Khung dữ liệu] chứa dữ liệu thời tiết thô (raw) có thể từ file CSV, file upload, hoặc dữ liệu vừa crawl qua API.

4) Tiền xử lý Features

Bước 1 - Xây dựng features:

- (1) Sắp xếp theo thời gian;
- (2) Time features [Đặc trưng thời gian] (hour_sin/cos, month_sin/cos, day_of_week...);
- (3) Location features [Đặc trưng vị trí] (latitude/longitude encoding);
- (4) Lag features [Đặc trưng trễ];
- (5) Rolling features [Đặc trưng trượt] (mean, std);
- (6) Difference features [Đặc trưng hiệu];
- (7) Interaction features [Đặc trưng tương tác] (cross-feature products).

Bước 2 - Loại bỏ và căn chỉnh các cột:

- (1) Loại bỏ cột target (rain_total) nếu còn trong DataFrame;
- (2) Loại bỏ các cột metadata (timestamp, data_time, data_quality,...);
- (3) Căn chỉnh với all_feature_columns đã lưu: thêm cột thiếu, xóa cột thừa, reorder đúng thứ tự;

Bước 3 - Transform pipeline: Pipeline gồm 3 - 4 bước tùy config:

- (1) MissingValueHandler [Bộ xử lý giá trị thiếu] (strategy: median);
- (2) OutlierHandler [Bộ xử lý giá trị ngoại lai] (method: IQR, action: clip) - chỉ bật khi handle_outliers=True;
- (3) CategoricalEncoder (encoding: label);
- (4) WeatherScaler (scaler: standard).

Bước 4 - Safety net (đảm bảo model nhận input numeric):

- (1) Cột object [Đối tượng] → chuyển sang datetime [Ngày giờ]; nếu thành công → epoch [Thời điểm] seconds (int64 // 109);
- (2) Convert object /category [Phân loại] → category codes (numeric);

5) Predict

Stacking Ensemble hỗ trợ hai chế độ:

Chế độ 1 - Schema-aware routing [Định tuyến nhận biết lược đồ] (khi FoldSchemaModelBank đã load):

(1) Phát hiện mùa của mỗi sample [Mẫu] từ month_sin/month_cos + season centroids [Tâm cụm];

(2) Định tuyến đến classifier + regressor tốt nhất cho mùa đó (ví dụ: mùa mưa dùng LGB classifier + XGB regressor);

(3) $p_rain = cls_model.predict_proba()[:, 1] \rightarrow$ xác suất mưa;

(4) Nếu $p_rain > predict_threshold$ (0.4): $rain_mm = reg_model.predict() \rightarrow$ qua expml gate;

(5) Nếu $p_rain \leq threshold$: $rain_mm = 0.0$.

Chế độ 2 - Stacking trực tiếp (fallback):

(1) Cls stacking (K-fold OOF meta-classifier) $\rightarrow p_rain$;

(2) Nếu $p_rain > predict_threshold$: Reg stacking (K-fold OOF meta-regressor) $\rightarrow rain_mm$;

(3) Nếu không: $rain_mm = 0.0$.

Stacking Ensemble trả về thêm: p_rain [Xác suất mưa], has_rain [Có mưa], $rain_mm_ungated$, $routing_mode$ [Chế độ định tuyến], $schema_info$ [Thông tin lược đồ] (mùa đã được phát hiện, model đã dùng cho từng sample).

VI. KẾT QUẢ THỰC NGHIỆM, ĐÁNH GIÁ VÀ SO SÁNH MÔ HÌNH

A. Tổng quan thực nghiệm

1) Mô tả tập dữ liệu

BẢNG V. PHÂN CHIA TẬP DỮ LIỆU CHO THỰC NGHIỆM.

Tập dữ liệu	Số mẫu	Vai trò
Train	289.156	Huấn luyện mô hình
Validation	36.144	Tinh chỉnh, early stopping [Dừng sớm]
Test	36.145	Đánh giá cuối cùng (không tham gia huấn luyện)

2) Cấu hình thực nghiệm

Tập dữ liệu sử dụng trong nghiên cứu được thu thập từ 52 trạm quan trắc khí tượng khu vực Đồng bằng sông Cửu Long (ĐBSCL) trong giai đoạn từ tháng 12/2025 đến tháng 03/2026, bao gồm tổng cộng 361.445 bản ghi sau khi trải qua quy trình tiền xử lý.

	Tổng dataset	: 361,445 dòng
	Train set (80%)	: 289,156 dòng x 42 cột
	Valid set (10%)	: 36,144 dòng x 42 cột
	Test set (10%)	: 36,145 dòng x 42 cột

Hình 6. Thống kê dữ liệu

BẢNG VI. CẤU HÌNH THỰC NGHIỆM.

Thông số	Giá trị
Biến mục tiêu (Target)	Rain_total - tổng lượng mưa (mm)
Tầm dự báo (Forecast horizon)	24 giờ
Ngưỡng phân loại mưa/không mưa	0,1 mm
Định nghĩa ngày mưa	Lượng mưa $\geq 0,1$ mm

Ngưỡng phân loại mưa/không mưa được chọn ở mức $rain_total \geq 0.1$ mm dựa trên ba căn cứ chính:

(1) Trong nhiều nghiên cứu, DRT được định nghĩa một cách tùy ý là 0,1 mm/ngày vì đây là độ chính xác thông thường của hầu hết các máy đo mưa phổ biến (Moon et al. 1994; Martín-Vide và Gómez 1999; Tennant và Hewitson 2002) [12];

(2) Kết quả thực nghiệm trên dữ liệu đề tài - nhóm nghiên cứu đã thử nhiều mức ngưỡng (0.01 / 0.05 / 0.1 / 0.2 / 0.5 / 1.0 mm); ngưỡng 0.1 mm cho kết quả tốt nhất với F1-Score = 86.22%, Recall [Độ phủ] = 88.21%, Accuracy = 80.70%, đồng thời tỉ lệ lớp dương (~35%) không gây mất cân bằng nghiêm trọng;

(3) Phân tích phân bố lớp trên tập train cho thấy dữ liệu có tính mất cân bằng rõ rệt với khoảng 52,1% mẫu không mưa ($rain_total < 0.1$ mm) và 47,9% mẫu có mưa ($rain_total \geq 0.1$ mm), phản ánh đúng đặc trưng khí hậu nhiệt đới gió mùa của khu vực ĐBSCL.

3) Các kịch bản đánh giá

Kịch bản đánh giá chuyên biệt bên cạnh đánh giá tổng thể trên tập test:

(1) Kịch bản theo cường độ mưa: Tập test được phân thành bốn nhóm dựa trên giá trị $rain_total$ thực tế:

- Không mưa: $rain = 0$ mm;
- Mưa nhẹ: $0 < rain \leq 2,5$ mm;
- Mưa vừa: $2,5 < rain \leq 7,5$ mm;
- Mưa lớn: $rain > 7,5$ mm.

(2) Kịch bản theo mùa: Tập test được phân chia theo hai mùa đặc trưng của ĐBSCL thông qua đặc trưng month_sin/month_cos:

- Mùa mưa (tháng 5 - tháng 10);
- Mùa khô (tháng 11 - tháng 4 năm sau);

4) Cấu hình máy tính thực nghiệm

Installed Physical Memory (RAM)	8.00 GB
Total Physical Memory	7.83 GB
Available Physical Memory	1.46 GB
Total Virtual Memory	22.0 GB
Available Virtual Memory	10.1 GB
Page File Space	14.2 GB

Hình 7. Cấu hình của máy tính cá nhân.

B. Kết quả mô hình Stacking Ensemble

1) Đánh giá hồi quy - Dự đoán lượng mưa

BẢNG VII. BẢNG ĐÁNH GIÁ HỒI QUY – STACKING ENSEMBLE.

Chỉ số	Tập Train	Tập Test	Đánh giá
R^2	0,4669	0,3522	Giải thích ~35,2% biến động lượng mưa
RMSE (mm)	0,6350	0,7616	Sai số trung bình căn ~0,76 mm
MAE (mm)	0,4335	0,5595	Sai số tuyệt đối trung bình ~0,56 mm
MBE [Sai số lệch trung bình] (mm)	0,0241	-0,0628	Thiên lệch nhẹ âm: dự đoán thấp hơn thực tế một chút
Pearson r [Hệ số tương quan Pearson]	0,6840	0,5980	Tương quan tuyến tính trung bình
sMAPE [Sai số phần trăm trung bình đối xứng] (%)	70,1160	77,8860	Sai số phần trăm


Stacking Ensemble đạt MAE = 0,56 mm, RMSE = 0,76 mm, Pearson r = 0,60, MBE [Sai số lệch trung bình] $\approx -0,06$ mm và $R^2 = 0,35$ trên tập test (R^2 gap = 0,11; RMSE ratio = 1,20 – Good Fit [Phù hợp tốt], không overfit). Sai số ~0,5 mm nhỏ hơn biên độ các nhóm cường độ khí tượng (nhẹ < 2,5 mm, vừa 2,5 - 7,5

mm, lớn > 7,5 mm), không làm thay đổi nhóm cường độ bản tin dự báo. MBE ≈ 0 xác nhận không có thiên lệch hệ thống; $R^2 \approx 0,35$ hợp lý khi phân phối zero-inflated làm giảm phương sai nền. Kết hợp với F1 = 86,22% ở nhánh phân loại, kiến trúc hai tầng đáp ứng đồng thời: ra quyết định có/không mưa tin cậy và ước lượng lượng mưa sát thực tế tại trạm.

BẢNG VIII. HIỆU NĂNG HỒI QUY CỦA STACKING ENSEMBLE THEO CƯỜNG ĐỘ MƯA (TẬP TEST).

Nhóm cường độ	Ngưỡng (mm)	Số mẫu	Tỉ lệ (%)	MAE (mm)	RMSE (mm)	Bias [Độ lệch] (mm)
Không mưa	= 0	18.841	52,13	0,1834	0,3915	+0,1742
Mưa nhỏ	(0 – 2,5]	14.986	41,46	0,6129	0,8271	-0,2046
Mưa vừa	(2,5 – 7,5]	2.318	6,41	1,7842	2,3517	-1,4235
Mưa lớn	> 7,5	0	0,00	–	–	–

Mô hình ổn định ở Không mưa (MAE 0,18 mm) và Mưa nhỏ (MAE 0,61 mm, 41% tập test). Ở Mưa vừa MAE tăng lên 1,78 mm (bias -1,42 mm) do đặc tính zero-inflated. Mưa lớn không xuất hiện vì dữ liệu thu thập trong mùa khô ĐBSCL. Kết quả được báo cáo dưới góc nhìn prototype [nguyên mẫu] (52 trạm, 5 tỉnh ĐBSCL, 92 ngày); mở rộng không gian-thời gian và huấn luyện lại định kỳ là điều kiện cần trước khi triển khai diện rộng.



Hình 8. Biểu đồ đánh giá hồi quy – Stacking Ensemble .

2) Đánh giá phân loại - Phát hiện mưa

BẢNG IX. BẢNG ĐÁNH GIÁ PHÂN LOẠI VÀ PHÁT HIỆN MƯA – STACKING ENSEMBLE.

Chỉ số	Giá trị
Accuracy	80,70%
Precision [Độ chính xác]	84,32%
Recall	88,21%
F1-Score [điểm đánh giá cân bằng giữa Precision và Recall]	86,22%
CSI [Chỉ số nghiêm trọng bão]	0,7578
FAR [Tỷ lệ cảnh báo sai]	15,68%
ROC-AUC	0,8133
Rain Detection	79,46%


BẢNG X. BẢNG MA TRẬN NHẦM LẦN

	Dự đoán: Không mưa	Dự đoán: Có mưa
Thực tế: Không mưa	TN [Âm tính thực (True Negative)] = 7.334	FP [Dương tính giả (False Positive)] = 4.056
Thực tế: Có mưa	FN [Âm tính giả (False Negative)] = 2.916	TP [Dương tính thực] = 21.815

Nhánh phân loại đạt Precision 84,32%, Recall 88,21%, F1 – Score 86,22%, CSI 0,7578, ROC-AUC 0,8133 và FAR 15,68% (TN [Âm tính thực (True Negative)] = 7.334; TP [Dương tính thực] = 21.812; Accuracy 80,70%; Rain Detection 79,46%). Khi cảnh báo mưa thì đúng 84,3% và phát hiện 88,2% sự kiện mưa thực tế; Recall cao được ưu tiên so với giảm FAR cho ứng dụng nông nghiệp/ngập cục bộ – cân bằng qua predict_threshold = 0,4.

Tỷ lệ mưa: Không mưa $\approx 68 : 32$ (cuối mùa khô – đầu mùa chuyển mưa); F1 - Score và CSI là chỉ số đáng tin cậy nhất trong điều kiện mất cân bằng lớp (ít phụ thuộc tỉ lệ lớp nền). ROC-AUC = 0,8133 xác nhận xếp hạng p_rain ổn định trên toàn dải ngưỡng. Kết quả giới hạn trong 92 ngày mùa khô, 5 tỉnh ĐBSCL – concept drift [Trôi khái niệm] có thể xảy ra ở mùa mưa hoặc

vùng khác, giám sát drift và huấn luyện lại định kỳ (mục VII, C) là bắt buộc trước khi vận hành diện rộng.



Hình 9. Biểu đồ phân tích phân loại của mô hình Stacking Ensemble trên tập kiểm tra.

3) Đánh giá kích thước của mô hình

BẢNG XI. KẾT QUẢ ĐÁNH GIÁ KÍCH THƯỚC MÔ HÌNH.

STT	Tên file	Kích thước
1	Model.pkl	23,79 MB
2	Transform_pipeline.pkl	24.54 MB
3	Feature_list.pkl	16.12 MB
4	Train_info.json	3.39 MB
5	Metrics.json	1.59 MB

Theo kết quả thống kê, toàn bộ artifacts của mô hình Stacking Ensemble sau khi huấn luyện chỉ chiếm gần 70 MB, trong đó file trọng số mô hình (Model.pkl) - thành phần quan trọng nhất phục vụ quá trình suy luận - chỉ nặng 23.79 MB cho phép mô hình được tải và chạy suy luận trực tiếp trên máy cục bộ mà không đòi hỏi bộ xử lý đồ họa hay hạ tầng điện toán chuyên dụng.

4) So sánh Stacking Ensemble với các mô hình lớn dự báo thời tiết

BẢNG XII. SO SÁNH STACKING ENSEMBLE VỚI CÁC MÔ HÌNH LỚN TRONG DỰ BÁO THỜI TIẾT.

Tiêu chí	Pangu-Weather [13]	GraphCast [14]	FourCastNet [15]	Stacking Ensemble (đề xuất)
Tham số	~256 triệu	~36,7 triệu	~75 triệu	Model ~23,79 MB
Phần cứng train	192 Graphics Processing Unit [Bộ xử lý đồ họa] V100	32 Thermoplastic polyurethane [Bộ xử lý tensor TPU] v4	64 Graphics Processing Unit [Bộ xử lý đồ họa] A100	1 CPU [Bộ xử lý trung tâm] phổ thông
Thời gian train	~16 ngày x 4 mô hình	~4 tuần	~16 giờ	Vài phút – vài giờ
Triển khai	Siêu máy tính	TPU cloud [Đám mây TPU]	GPU server [Bộ xử lý đồ]	Máy tính cá nhân / edge

			họa máy chủ]	[Thiết bị biên]
--	--	--	--------------	-----------------

VII. KẾT LUẬN, HẠN CHẾ, HƯỚNG PHÁT TRIỂN

A. Kết luận

Qua quá trình đánh giá toàn diện trên cùng tập test gồm 36.145 mẫu (đã xác minh bằng np.allclose = True), với 12 chỉ số đo lường trên cả hai nhóm hồi quy và phân loại, nghiên cứu rút ra kết luận:

- Stacking Ensemble là mô hình tốt hơn cho hệ thống dự báo thời tiết với Accuracy = 80,70%, F1 - Score = 86,22%, CSI = 0,7578, trạng thái Good Fit;

- Kiến trúc hai nhánh (classification + regression) của Stacking cho thấy ưu thế rõ rệt trong bài toán dự báo mưa, vì cho phép xử lý riêng biệt hai nhiệm vụ: phát hiện sự kiện mưa và ước lượng lượng mưa;

- Mô hình đều có R^2 ở mức trung bình ($< 0,5$), phản ánh bản chất khó dự đoán của hiện tượng mưa - một biến thời tiết có tính ngẫu nhiên cao, chịu ảnh hưởng bởi nhiều yếu tố phi tuyến.

B. Hạn chế

- Phạm vi địa lý hẹp: Chỉ 5 tỉnh ĐBSCL (An Giang, Cà Mau, Cần Thơ, Đồng Tháp, Vĩnh Long);

- Thiếu nguồn dữ liệu quan trọng: Không có radar, ảnh vệ tinh, dữ liệu khí quyển tầng cao, NWP [Dự báo thời tiết số];

- Lịch sử ngắn: 92 ngày, thiếu dữ liệu mưa cực đoan (0 mẫu $> 7.5\text{mm}$ trong tập test);

- Dự báo đơn biến: Chỉ dự báo rain_total, không dự báo nhiệt độ, độ ẩm, gió...;

- Tầm dự báo cố định: Chỉ 24h, không hỗ trợ đa tầm (6h, 12h, 48h, 72h);

- Không auto-retrain: Mô hình không tự cập nhật khi có dữ liệu mới do chưa triển khai lên server [Máy chủ];

- Không giám sát model drift: Thiếu cơ chế phát hiện suy giảm chất lượng theo thời gian;

- Chưa tối ưu hiệu năng: Chưa có caching, load balancing cho production;

C. Hướng phát triển

1) *Hướng phát triển mô hình*: Về mô hình, nghiên cứu có thể mở rộng sang các kiến trúc học sâu như LSTM [Bộ nhớ dài-ngắn], Temporal Fusion Transformer [Mô hình Transformer hợp nhất thời gian] và Graph Neural Network [Mạng nơ-ron đồ thị]; phát triển dự báo đa mốc thời gian từ 1h đến 72h; đồng thời cải thiện cân bằng Precision -Recall, giảm cảnh báo sai và bổ sung khoảng tin cậy cho dự báo lượng mưa.

2) *Hướng ứng dụng thực tiễn*: Về ứng dụng thực tiễn, hệ thống có thể hỗ trợ ra quyết định trong nông nghiệp, tham gia vào Smart City [Thành phố thông minh] như quản lý thoát nước và giao thông, đồng thời trở thành nền tảng nghiên cứu biến đổi khí hậu khi dữ liệu tích lũy đủ dài.

LỜI CẢM ƠN

Nhóm tác giả xin trân trọng cảm ơn sự hỗ trợ và đồng hành của các cá nhân, tổ chức và nguồn tài liệu liên quan trong suốt quá trình thực hiện nghiên cứu. Những hỗ trợ này đã góp phần quan trọng vào việc hoàn thiện nội dung và kết quả của bài báo.

TÀI LIỆU THAM KHẢO

- [1] M. A. Ganaie, M. Hu, A. K. Malik, M. Tanveer, and P. N. Suganthan, "Ensemble deep learning: A review," *Engineering applications of artificial intelligence*, vol. 115, p. 105151, 2022.
- [2] I. D. Mienye and Y. Sun, "A survey of ensemble learning: Concepts, algorithms, applications, and prospects," *Ieee Access*, vol. 10, pp. 99129-99149, 2022.
- [3] A. Sampson, A. James, and V. Tripathi, "Optimizing breast cancer prediction through stacking ensemble machine learning models: a comparative analysis," *Journal of Electrical Systems and Information Technology*, vol. 13, no. 1, p. 9, 2026.
- [4] T. E. Ali, Y.-W. Chong, S. Manickam, M. N. Yusoff, K.-L. A. Yau, and A. D. Zoltan, "A stacking ensemble model with enhanced feature selection for distributed Denial-of-Service detection in Software-Defined networks," *Engineering, Technology & Applied Science Research*, vol. 15, no. 1, pp. 19232-19245, 2025.
- [5] C. Bergmeir and J. M. Benítez, "On the use of cross-validation for time series predictor evaluation," *Information Sciences*, vol. 191, pp. 192-213, 2012.
- [6] C.-E. Lee and S. U. Kim, "Applicability of zero-inflated models to fit the torrential rainfall count data with extra zeros in South Korea," *Water*, vol. 9, no. 2, p. 123, 2017.
- [7] T. E. Ali, Y.-W. Chong, and S. Manickam, "Machine learning techniques to detect a DDoS attack in SDN: A systematic review," *Applied Sciences*, vol. 13, no. 5, p. 3183, 2023.
- [8] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, 2016, pp. 785-794.
- [9] G. Ke *et al.*, "Lightgbm: A highly efficient gradient boosting decision tree," *Advances in neural information processing systems*, vol. 30, 2017.
- [10] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "CatBoost: unbiased boosting with categorical features," *Advances in neural information processing systems*, vol. 31, 2018.
- [11] L. Breiman, "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [12] H. Reiser and H. Kutiel, "Rainfall uncertainty in the Mediterranean: definitions of the daily rainfall threshold (DRT) and the rainy season length (RSL)," *Theoretical and Applied Climatology*, vol. 97, no. 1, pp. 151-162, 2009.
- [13] K. Bi, L. Xie, H. Zhang, X. Chen, X. Gu, and Q. Tian, "Accurate medium-range global weather forecasting with 3D neural networks," *Nature*, vol. 619, no. 7970, pp. 533-538, 2023.
- [14] R. Lam *et al.*, "Learning skillful medium-range global weather forecasting," *Science*, vol. 382, no. 6677, pp. 1416-1421, 2023.
- [15] J. Pathak *et al.*, "Fourcastnet: A global data-driven high-resolution weather model using adaptive fourier neural operators," *arXiv preprint arXiv:2202.11214*, 2022.

GIỚI THIỆU THÔNG TIN TÁC GIẢ

	Võ Anh Nhật , sinh viên năm thứ 2 ngành/chuyên ngành Khoa học dữ liệu và AI tại Trường Đại học Giao thông vận tải Thành phố Hồ Chí Minh. Hướng quan tâm học thuật bao gồm : học máy, học máy kết hợp, khoa học dữ liệu.
	Võ Huỳnh Anh Tuấn , sinh viên năm thứ 2 ngành/chuyên ngành Khoa học dữ liệu và AI tại Trường Đại học Giao thông vận tải Thành phố Hồ Chí Minh. Hướng quan tâm học thuật bao gồm: học máy, học máy kết hợp, khoa học dữ liệu.
	Trương Hoài Tú , sinh viên năm thứ 2 ngành/chuyên ngành Khoa học dữ liệu và AI tại Trường Đại học Giao thông vận tải Thành phố Hồ Chí Minh. Hướng quan tâm học thuật bao gồm: học máy, học máy kết hợp, khoa học dữ liệu.
	Dư Quốc Việt , sinh viên năm thứ 2 ngành/ chuyên ngành Khoa học dữ liệu và AI tại Trường Đại học Giao thông vận tải Thành phố Hồ Chí Minh. Hướng quan tâm học thuật bao gồm: học máy, học máy kết hợp, khoa học dữ liệu.
	Trần Anh , học sinh tại Trường Phổ thông Năng khiếu, Đại học Quốc gia Thành phố Hồ Chí Minh. Hướng quan tâm học thuật bao gồm: học máy, học máy kết hợp, khoa học dữ liệu.